

CD-MambAtt 研究方案完整指南

生成时间：2026-03-30

状态：当前唯一保留的最终方案

速读摘要

一句话总结这个项目：在 MambAtt（Mamba + 自监督 RUL 预测）的基础上，设计跨域自监督机制，使模型在目标域只有极少标注数据的情况下，仍能准确预测工业设备的剩余寿命。

核心出发点：MambAtt 已经证明了 Mamba + 自监督预训练在单域少样本 RUL 预测上有效，但它完全没有处理跨域问题。伪标签机制在域偏移下直接失效，特征空间也存在错位。这就是本项目存在的价值。

一、研究背景与动机

1.1 什么是 RUL 预测

预测工业设备（如航空发动机、轴承）在正常工作到彻底故障之前还能运行多久。

核心价值：提前安排维修，避免设备突然坏掉造成损失。

1.2 核心难点

普通 RUL 预测的问题：需要大量从新到坏的完整标注数据。但现实中：

- 新工厂、新工况的数据极少
- 不同工况下设备退化模式完全不同

本项目要解决的问题：源域（旧工况）有大量数据，目标域（新工况）只有极少数据，如何仍然准确预测目标域的 RUL。

三个关键词：**RUL**（寿命预测）+ **跨域**（旧→新工况）+ **少样本**（新工况数据极少）

1.3 为什么选 MambAtt 作为基础

MambAtt（Mamba-attention，2025年8月，发表于 RESS，IF≈13，Q1）是目前最接近本方向的论文。

它做了什么：

- Mamba 编码器 + Transformer 解码器
- 三个自监督损失：时序顺序损失、N-tuplet 对比损失、伪标签损失
- 证明了在单域少样本场景下，先用无标签数据预训练编码器，再冻结编码器只微调预测头，效果很好

它没做什么（就是你的切入点）：

- 所有实验都在同一子数据集内部（如 FD001 内），没有跨域
- 伪标签基于原始传感器数值的 K-means，跨域时直接失效
- 没有任何域对齐机制

二、竞品论文现状

论文组合	是否有人做
Mamba + RUL	✅ 很多
Mamba + 少样本 RUL	✅ MambAtt (2025.8)
few-shot + 跨域 RUL	✅ 有一批（用 LSTM/Transformer）
Mamba + 少样本 + 跨域 RUL	❌ 目前没有
对抗域适应 + RUL (GRL)	✅ 2021年起大量存在，已是成熟技术
伪标签 + 跨域 RUL	✅ 有（但未和 Mamba 自监督结合）
Domain-Conditioned Mamba（工况 prompt）	❌ RUL 领域没有

结论：空位真实存在，时间窗口有限，需要尽快推进。

三、已识别的技术矛盾

矛盾1: Mamba 与少样本的冲突

Mamba 隐藏状态需要足够数据初始化。MambAtt 的解法是预训练+冻结编码器，这个思路可以直接借鉴。

矛盾2: Mamba 自适应性 vs 跨域泛化需求

Mamba 的参数动态调整天然倾向学"工况特定表示"，而跨域需要"跨工况通用特征"。这是核心矛盾，论文 Method 的核心创新就在于解决它。MambAtt 自己也承认 FD004（多工况）上 Transformer 比 Mamba 更稳，这个矛盾在跨域场景会被放大。

矛盾3: 特征空间错位导致伪标签打错

跨域时源域和目标域特征空间本身是错位的，直接用源域聚类中心给目标域打标签会打错。这是"鸡生蛋蛋生鸡"问题，解法是渐进式框架。

矛盾4: 跨域数据归一化失效

MambAtt 使用统一 Z-score 归一化，参数由整个训练集计算。跨域时，FD001 和 FD004 的传感器均值和方差完全不同，用源域参数归一化目标域数据会直接引入偏差，破坏特征提取。

解决方案：放弃全局统一 Z-score，改为独立计算各域的均值和方差（Domain-specific Normalization），或引入实例归一化（Instance Normalization），避免物理尺度差异污染特征。

四、最终选定的技术方案：CD-MambAtt


4.1 方案命名

Cross-Domain MambAtt (CD-MambAtt)

论文标题候选：

- Cross-Domain Self-Supervised Mamba for Remaining Useful Life Prediction under Variable Operating Conditions
- CD-MambAtt: Adaptive Cross-Domain Mamba with Progressive Pseudo-Label Alignment for Few-Shot RUL Prediction

4.2 整体架构



4.3 三个核心创新点

创新点一：特征空间渐进式伪标签（解决矛盾3）

原问题：MambAtt 在原始传感器数值上做 K-means，不同工况数值范围不同，直接打错标签。

解决方案（三步渐进式闭环）：

Step 1 - 粗对齐：先用 MMD（最大均值差异）或轻量 GRL 对齐源域和目标域的特征空间。不需要任何标签，只求把两个偏离的特征分布大体拉近。

Step 2 - 打伪标签：粗对齐后，用源域的退化阶段聚类中心（Centroids）给目标域特征打伪标签。关键补丁：置信度过滤 —— 只有距离源域聚类中心足够近的目标域样本才参与训练，距离模糊的样本直接丢弃。随着训练进行阈值逐渐放宽。

Step 3 - 精细对比：有了相对可靠的伪标签，应用跨域 N-tuplet Loss，把同标签的跨域特征拉近，不同标签的推开。进一步促使两个域特征对齐。

为什么这个逻辑严密：即使粗对齐不完美，置信度过滤也能防止错误传播。随着迭代进行，模型自我纠错，整个闭环越来越准。写进论文里审稿人会认可这是专业的设计。

创新点二：跨域 N-tuplet 对比损失（解决矛盾2）

原问题：MambAtt 的 N-tuplet Loss 只在同一域内做，无法对齐跨域特征。

改进：

- 查询样本：源域退化阶段 k 的某个样本
- 正样本：目标域中被打上"阶段 k"伪标签的样本
- 负样本：目标域中被打上其他阶段伪标签的样本

让 Mamba 编码器被迫忽略域差异，把两个域的同阶段退化特征映射到特征空间的同一区域。

创新点三：局部单调性损失（替代寿命百分比）

原问题："寿命百分比"在没有完整寿命数据的数据集（右删失数据）上无法计算。

改进：不计算全局百分比，只施加局部约束：退化必然是单调变差的。要求 $Feature(t)$ 对应的退化指标必然大于 $Feature(t-k)$ ，这个约束在任何数据集上都成立。

4.4 总损失函数

$$L_{Total} = L_{Task} + \lambda_1 L_{MMD} + \lambda_2 L_{Cross-Contrastive} + \lambda_3 L_{Monotonic}$$

- L_{Task} ：源域 RUL 预测监督损失
- L_{MMD} ：粗对齐损失（最大均值差异）
- $L_{Cross-Contrastive}$ ：带置信度过滤的跨域 N-tuplet 对比损失
- $L_{Monotonic}$ ：局部单调性自监督损失

$\lambda_1, \lambda_2, \lambda_3$ 为权重超参数，需要消融实验验证敏感性。

五、数据集与实验设计

5.1 数据集

主数据集：**C-MAPSS**（航空发动机退化，NASA）

子集	工况数	故障模式	训练发动机数
FD001	1	1	100
FD002	6	1	260
FD003	1	2	100
FD004	6	2	249

跨域任务对（第一批，基础验证）：

- FD001 → FD003（单工况→单工况，故障模式不同）
- FD003 → FD001（反向）
- FD002 → FD004（多工况→多工况，故障模式不同）
- FD004 → FD002（反向）

跨域任务对（第二批，高难度验证）：

- FD001 → FD002（单工况/单故障 → 多工况/单故障）
- FD001 → FD004（最简单 → 最复杂，含金量最高）

如果模型能把 FD001 学到的知识泛化到 FD004，论文说服力会大幅提升。

辅助数据集：**XJTU-SY**（轴承寿命） 用于验证方法不局限于航空发动机，增强论文说服力。

5.2 Few-shot 设定

目标域标注样本数：1-shot、3-shot、5-shot、10-shot

5.3 评估指标

- RMSE（整体预测误差）
- Score（非对称评分函数，对提前预测故障惩罚更重）
- 不同 shot 数下的性能曲线
- 多次重复实验的均值和方差（证明稳定性）

5.4 Baseline 清单

Baseline	作用
Source-only LSTM/GRU	不做跨域适配的传统模型上限
Source-only Transformer	强编码器对照
MambAtt（原论文，直接跨域）	证明原方法在跨域场景失效
现有 few-shot cross-domain RUL 方法	证明我们不只是打弱对手
Transformer encoder + 同样跨域适配模块	控制变量，证明 Mamba 编码器的贡献
CD-MambAtt（完整方法）	最终对比

5.5 消融实验

消融项	目的
去掉粗对齐（Step 1）	验证粗对齐的必要性
去掉置信度过滤	验证过滤机制的必要性
去掉跨域对比损失（Step 3）	验证精细对齐的贡献
去掉单调性损失	验证该损失的贡献
把 Mamba 编码器替换为 Transformer 编码器（纯 Transformer 架构）	验证 Mamba 编码器的优势

六、论文写作逻辑

6.1 Abstract & Introduction 叙事主线

- 背景：RUL 预测对工业很重要，Mamba 在时序建模上有优势，最新工作 MambAtt 在少样本单域 RUL 上达到 SOTA。
- 转折：然而，现有 Mamba RUL 方法强烈依赖单一域内的数据分布。MambAtt 的原始伪标签机制在跨域（域偏移）场景下会直接失效，且缺乏任何特征对齐机制。
- 提出方法：我们提出 CD-MambAtt，设计了基于渐进式特征空间对齐的跨域自监督框架，包含粗对齐→置信度伪标签→跨域对比三步闭环，并将 N-tuplet Loss 扩展至跨域级别。
- 实验结果：在 C-MAPSS 跨子集任务上显著优于 baseline，在 XJTU-SY 轴承数据集上进一步验证了泛化性。

6.2 创新点归纳（给审稿人看）

1. 首次在 Mamba 自监督框架下引入跨域适配，揭示并解决了原始伪标签机制在域偏移下失效的问题。
 2. 提出渐进式特征空间伪标签分配机制，通过置信度过滤防止错误传播。
 3. 将 N-tuplet 对比损失扩展至跨域级别，实现跨域退化特征对齐。
-

七、算力与工程规划

7.1 算力

硬件：Windows RTX 4060 Laptop，通过 Mac 远程 SSH 进 WSL Ubuntu。评估：够用，但比预期紧，需注意：

- C-MAPSS 数据量本身不大
- Few-shot episode training 会降低训练效率
- 多次重复实验 × 4个shot设定 × 消融实验，实际实验量是直觉的3-5倍

7.2 环境配置关键点

- 不要在纯 **Windows** 下配 **Mamba**，必须在 WSL2 Linux 环境下
- 你已有的 WSL Ubuntu 环境是正确选择
- Mamba 依赖：`mamba-ssm` 和 `causal-conv1d`，需要特定 CUDA 版本匹配
- 备用：如果环境实在配不起来，考虑用 AutoDL 云服务器（便宜，环境干净）

7.3 代码获取策略

Plan A（首选，今天执行）：发邮件给原作者要代码：hs.yoon@yonsei.ac.kr

邮件主题：`Inquiry regarding source code for "Mamba-attention: A self-supervised framework for efficient remaining useful life prediction"`

Plan B（备选）：自己搭，核心是 `state-spaces/mamba` 官方库 + PyTorch

TransformerEncoder。论文 Table 2 给出了所有超参数（`d_state=16`，3层Transformer等），复现难度中等。

Plan C（找平替）：GitHub 搜 `RUL-Mamba`，代码地址：<https://github.com/USTC-AI4EEE/RUL-Mamba>，先跑通任意一个 Mamba 处理 C-MAPSS 的代码。

八、时间规划

保研截止：2026年8月31日。今天：2026年3月29日。剩余约22周，几乎没有容错空间。

阶段	内容	估计时间
阶段0	发邮件要代码，配通环境	1周
阶段1	复现 MambAtt 基线，跑出跨域场景下失效的结果	2-3周
阶段2	实现 Mamba encoder 单独验证	2-3周
阶段3	实现跨域适配模块，接入完整框架	4-6周（风险最高）
阶段4	完整实验 + 消融 + 可视化	3-4周
阶段5	论文写作	3-4周

合计约 **15-21** 周，和剩余时间基本匹配，但没有容错空间。

九、目标期刊

第一目标（推荐）：

- Engineering Applications of Artificial Intelligence (EAAI)，Q1，对工程应用创新友好
- Measurement，Q1，接受率相对较高

第二目标（冲击）：

- Reliability Engineering & System Safety (RESS)，Q1，IF≈13，MambAtt 发的那本

不建议一开始直接冲：

- IEEE Transactions on Industrial Informatics (T-II)，Q1，竞争激烈，审稿周期长

十、当前最优先事项（按顺序）

1. 今天：发邮件给 hs.yoon@yonsei.ac.kr 要代码
2. 本周：在 GitHub 找 Mamba + C-MAPSS 的代码，配通 WSL 环境，跑起来第一个 baseline
3. 第2周：在 C-MAPSS 上运行 MambAtt 的直接跨域测试 (FD001→FD004)，记录失效的 RMSE 数字，这就是你论文 motivation 最有力的证据
4. 第2-3周：在纸上画出 CD-MambAtt 的系统框图，把三个创新点的损失函数写成公式

十一、需要继续读的论文（按优先级）

1. **A survey on few-shot learning for RUL prediction** (2025, RESS) —— 先读这篇建立全局地图
 2. **DPMA: Self-Supervised Dual-Path Meta Alignment Network for RUL** (2025, IEEE TIM) —— 最接近的技术路线
 3. **Meta-learning with deep flow kernel network for few-shot cross-domain RUL** (2024, RESS) —— 最直接的 baseline
 4. **Graph structure few-shot prognostics for machinery RUL** (2024, AEI) —— 了解图结构方向
 5. **Few-shot RUL prediction based on Bayesian meta-learning** (2025, EAAI) —— 了解不确定性方向
-

十二、一句话现状判断

方向选对了，竞品论文读完了，技术方案逻辑闭合，现在唯一缺的是动手写代码。一切讨论都不能替代跑起来的第一行实验结果。